

AI 使用说明

专业：经济统计学

学号：032402126

姓名：冯玉韬

1. 使用的 AI 工具

本次期末考试中，我使用了 **豆包AI** 作为辅助工具。

2. 使用 AI 的具体环节

- **数据清洗**：咨询正则表达式写法和pandas字符串提取方法
 - **数据可视化**：查询seaborn和matplotlib的图表参数设置
 - **错误排查**：解释代码报错原因，提供排查思路
 - **方法咨询**：查询异常值检测、相关分析等统计方法的实现
 - **结构建议**：咨询数据分析报告的组织方式
-

3. 主要提问内容或提示词摘要

1. 数据读取相关

- CSV文件中文乱码怎么办？有哪些常见编码格式？
- pandas读取CSV文件时指定编码的参数是什么？

2. 数据清洗相关

- 如何用正则表达式从字符串中提取数字？
- pandas的 `str.extract()` 方法怎么用？
- 从"3室2厅2卫"中提取室、厅、卫的数量，正则表达式怎么写？
- "中层(共31层)"这种格式，怎么分别提取楼层位置和总楼层数？
- 数据类型转换时遇到缺失值怎么办？

3. 缺失值与异常值相关

- 数据分析中缺失值一般怎么处理？
- IQR方法检测异常值的具体公式和实现代码？
- 房价数据的异常值应该直接删除吗？

4. 数据可视化相关

- matplotlib中文显示成方块怎么办？
- seaborn箱型图怎么按中位数排序？
- x轴标签太多太挤，有什么解决办法？
- 水平箱型图的参数怎么设置？
- 箱型图的异常值点大小怎么调整？

5. 分析方法相关

- 二手房数据分析一般从哪些维度入手？
- pandas按区域分组统计均价怎么写？
- 相关系数矩阵怎么解读？

6. 报告结构相关

- 数据分析报告一般是什么结构？
- 结论部分怎么写比较好？

4. 我对 AI 输出做了哪些检查、修改或取舍

4.1 数据清洗部分

- AI给出的正则表达式只能匹配标准格式，实际数据中有多种变体
- 我增加了对异常格式的处理，匹配失败的数据设为缺失值
- 楼层提取的正则表达式改了3次才覆盖所有情况
- 数据类型转换时，自己加上了 `errors='coerce'` 参数处理异常值

4.2 中文字体部分

- AI只给了Windows系统的字体设置方法（SimHei）
- 我自己写了自动检测系统可用字体的代码，支持Windows/Mac/Linux
- 增加了清除matplotlib字体缓存的步骤
- 把所有“元/m²”改成了“元/平方米”，避免特殊字符显示问题

4.3 箱型图部分

- AI建议用垂直箱型图+旋转标签，但12个区域还是太挤
- 我改成了水平箱型图，效果更好
- 水平箱型图的y轴标签在某些环境下显示有问题，我又调整了标签旋转和边距
- 异常值点太多太乱，我调小了点的大小，改成半透明灰色

4.4 异常值处理部分

- AI建议用IQR方法删除异常值
- 我考虑到二手房确实有高价房源，没有全部删除
- 只删除了特别极端的异常值，大部分高价房源保留
- 在分析结论中说明了价格分布的右偏特征

4.5 代码整体

- 没有直接复制粘贴AI生成的代码
- 所有代码都经过自己的理解和改写
- 每段代码都加了中文注释
- 运行测试后根据实际结果调整参数

5. 哪些分析结论是我根据数据自行判断得到的

以下分析结论都是我通过运行代码、查看数据结果后，自己总结得出的：

1. 区域分布结论

- 晋安区和仓山区房源数量最多，是市场主力区域
- 鼓楼区均价最高，体现了核心城区的地段价值
- 各区域房价差异明显，最高与最低区域差距较大

2. 价格分布结论

- 总价集中在150-250万元区间
- 均价集中在15000-25000元/平方米
- 价格呈右偏态分布，均值高于中位数，存在少数高价房源

3. 户型结构结论

- 3室2厅是绝对主流户型，占比最大
- 2室户型面向刚需群体，4室及以上大户型占比较小
- 房屋面积集中在80-120平方米区间

4. 影响因素结论

- 面积与总价呈显著正相关，相关系数约0.6左右
- 相同面积下，不同区域房价差异明显，地段溢价显著
- 不同房龄房源价格存在差异，次新房通常价格更高

5. 市场建议结论

- 刚需购房者可以重点关注晋安、仓山等供应量较大的区域
- 预算有限的购房者可以考虑闽侯、连江等周边区域
- 大户型和高价房源选择相对较少，需要更多时间挑选

说明：AI可以作为辅助工具，但不能代替独立分析。本报告的所有分析结论都基于数据结果，经过了本人的理解和判断。

提交日期：2026年6月24日